

Prezentacja projektu

Model LLM do klasyfikacji zwrotek polskiego rapu

Mateusz Błażek, Damian Wojtyczko

Zakres projektu

- **Cel:** dostrojenie **Qwen3.5-4B** i **Gemma-4-E2B** metodą **LoRA** do klasyfikacji zwrotek polskiego rapu (20 klas - artystów).
- **Dane:** samodzielne przygotowanie datasetu przez pobranie tekstów z Genius, parsowanie na zwrotki i czyszczenie.

Proces



Etap 1

przygotowanie danych (`dataset.ipynb`): pobieranie tekstów z Genius, parsowanie utworów na zwrotki, czyszczenie, podział train/test.



Etap 2

trening modeli (`trening-qwen.ipynb`, `trening-gemma.ipynb`): dostrajanie modeli w Jupyterze z biblioteką **Unsloth** i **Transformers**.



Etap 3

inferencja (`inferencja-qwen.ipynb`, `inferencja-gemma.ipynb`, `classify.py`): klasyfikacja zwrotek z adapterów LoRA i zapis wyników.



Etap 4

frontend (`quiz-app/`): aplikacja **React + Vite** z endpointem uruchamiającym skrypt Pythona w tle.

Pobieranie danych z Genius API

Teksty utworów pobierane automatycznie z platformy **Genius** poprzez bibliotekę **lyricsgenius**.

- **Lista artystów:** 18 polskich raperów/hip-hopowców - m.in. Pezet, Mata, Quebonafide, Sobel, Kabe, Żabson, Sentino, Diho, Young Igi, Young Leosia, Guzior, Avi, OG Olgierd, Bedoes 2115, Malik Montana, White 2115, Oki, Zeamsone.
- **Parametry pobierania:** do **250** najpopularniejszych utworów na artystę, **3** wątki pobierania utworów.
- **Cache:** surowe odpowiedzi API zapisywane w `dataset/lyrics/` (jeden plik JSON na artystę) - ponowne uruchomienie nie wymaga ponownego pobierania.
- **Obsługa błędów:** retry przy HTTP 429 (60 s) i błędach sieciowych (30 s), odrzucanie remiksów, wersji live i demo.

Przetwarzanie tekstów na zwrotki

Surowe teksty utworów dzielone na pojedyncze sekcje z przypisanym wykonawcą.

 **Wykrywanie zwrotek:** regex `[Zwrotka 1: Mata]`, `[Refren]`, `[Bridge]` itd.

 **Parsowanie wykonawców:** obsługa separatorów `&`, `,`, `+`, `/`, `i`, `oraz`, `x`, `feat.`, `ft.` - np.
"Mata & Quebonafide" - "Mata", "Quebonafide".

 **Czyszczenie:** usuwanie śmieci z Genius, odrzucanie sekcji krótszych niż **10 słów**.

 **Normalizacja etykiet:** aliasy (`Bedoes 2115` → `Bedoes`, `Avi (POL)` → `Avi`), sortowanie i deduplikacja współautorów.

Przygotowanie zbioru treningowego i testowego

Każdy rekord zawiera pola: `song`, `section`, `text`, `label`.

- **Przed filtrowaniem:** 9793 zwrotek, 8018 po czyszczeniu (min. 30 zwrotek na etykietę, usunięcie rzadkich gościnnych wersów).
- **Klasy:** 20 unikalnych etykiet (artystów) - m.in. Pezet (~547), Bedoes (~532), Żabson (~466), Sobel (~444), Mata (~426).
- **Podział główny:** 6815 zwrotek treningowych + 1203 testowych (`train_test_split`, stratyfikacja 85% / 15%, `random_state=42`).
- **Podział walidacyjny:** z train wydzielono 6133 na trening + 682 na walidację pod early stopping i wybór najlepszego checkpointu.
- **Pliki:** `dataset/train.json`, `dataset/test.json` - gotowe do wczytania w notebookach treningowych.

Klasyfikator Bayesa

Na początku zrobiliśmy klasyfikację przy użyciu klasyfikatora Bayesa jako prosty baseline.

- **Preprocessing tekstu:** zamiana `\n` na spacje, usunięcie nadmiaru białych znaków.
- **Wektoryzacja TF-IDF:** n-gramy (1, 2), `lowercase=True`, **polskie stop words** (m.in. *i, w, że, się, nie*), `sublinear_tf=True`, `min_df=2`.
- **Klasyfikator:** `MultinomialNB(alpha=0.1)` — wygładzenie zapobiega zerowym prawdopodobieństwom dla rzadkich słów.

Klasifikator Bayesa — wyniki

Ewaluacja na **1203** zwrotkach testowych (niewidziane podczas treningu na **6815** próbkach):

METRYKA	WARTOŚĆ
Accuracy	63%
Macro avg F1	0,53
Weighted avg F1	0,61

Zadanie klasyfikacji

Modele LLM dostrajane do **klasyfikacji sekwencji**, nie do generowania tekstu.

- ➔ **Wejście:** tekst zwrotki opakowany w prompt instrukcyjny: *"Przeczytaj poniższą zwrotkę polskiego utworu rapowego i określ, kto jest wykonawcą."*
- 📄 **Format:** chat template modelu (role `user`) → tokenizacja → forward pass → softmax na logitach głowicy klasyfikacyjnej.
- ➔ **Wyjście:** predykcja z jedną z **20** etykiet (artystów) + prawdopodobieństwo dla każdej klasy.
- 📈 **Metryki ewaluacji:** **accuracy** (dokładność), **macro-F1** (uśredniony F1 Score liczony po klasach), **top-3 accuracy** (dokładność w top 3 predykcjach).

Trening modeli — konfiguracja

Oba modele trenowane metodą **LoRA** (Parameter-Efficient Fine-Tuning) - trenowane są adaptery, nie cały model.

- **Modele bazowe:** `Qwen3.5-4B` oraz `Gemma-4-E2B`.
- **LoRA:** `r=32`, `lora_alpha=64`, `lora_dropout=0.0`; trenowana głowica klasyfikacyjna (`modules_to_save=["score"]`).
- **Hiperparametry:** batch 32 (train) / 64 (eval), LR LoRA **2e-4**, LR głowicy **1e-3**, label smoothing **0.1**.
- **Trening:** Qwen — **9** epok, Gemma — zastopowane po **9. epoce**, early stopping wg **eval_f1_macro**, max długość sekwencji **650** tokenów (~99. percentyl).

Przebieg treningu — Qwen3.5-4B

Walidacyjny **macro-F1** rośnie szybko i stabilizuje się ok. epoki 8 (najlepszy checkpoint).

EPOKA	TRAIN LOSS	VAL LOSS	VAL MACRO-F1
1	3,3971	3,2223	0,0238
2	2,8476	2,6708	0,3312
3	1,8396	2,2976	0,4712
4	1,2791	2,1723	0,5784
5	1,1242	2,0636	0,5703
6	1,0740	2,0379	0,5897
7	1,0614	2,0789	0,6043
8	1,0736	2,0813	0,6316
9	1,0596	2,1043	0,6215

Przebieg treningu — Gemma4-E2B

Early stopping zatrzymał trening po **9. epoce**; najlepszy checkpoint to **epoka 7**.

EPOKA	TRAIN LOSS	VAL LOSS	VAL MACRO-F1
1	3,4699	3,3164	0,0163
2	2,9889	2,8195	0,2597
3	2,1955	2,5778	0,4017
4	1,5814	2,5131	0,5019
5	1,2714	2,6305	0,5308
6	1,2483	2,0518	0,5850
7	1,1413	2,0329	0,5928
8	1,1818	2,2719	0,5803
9	1,1329	2,0406	0,5828

Trening modeli — wyniki

Porównanie na zbiorze testowym (1203 zwrotek, niewidziane podczas treningu):

MODEL	ACCURACY	MACRO-F1	TOP-3 ACCURACY
Qwen3.5-4B	64,42%	0,6311	73,15%
Gemma4-E2B	57,19%	0,5968	72,57%

- **Qwen** osiąga wyższą dokładność top-1 — lepsze rozróżnianie artystów przy pierwszej predykcji.
- **Top-3** obu modeli jest zbliżone (~73%) — model często ma poprawnego artystę w gronie trzech najbardziej prawdopodobnych.

Inferencja

Notebooki inferencyjne (`inferencja-qwen.ipynb`, `inferencja-gemma.ipynb`) pokazują, jak wytrenowany model klasyfikuje nowe zwrotki — krok po kroku.

- **Co można tam zobaczyć:** wczytanie modelu, predykcję pojedynczej zwrotki i ranking artystów z poziomem pewności (np. "Sobel 78%, Mata 11%...").
- **Ładowanie:** `FastModel.from_pretrained` (model bazowy) + `PeftModel.from_pretrained` (adaptery LoRA i głowica `score`).
- **Urządzenia:** automatyczny wybór **CUDA** / **MPS** (Apple Silicon) / **CPU**.
- **Wyjście:** nazwa artysty + prawdopodobieństwo (softmax po logitach głowicy klasyfikacyjnej).

Aplikacja quizowa

Nie byliśmy pewni jak interpretować metryki uzyskane w notebookach...

A może by tak po prostu zmierzyć się z modelami?

Powstała aplikacja quizowa "Quiz Rapowy", która zamiast metryk oferuje pojedynki - **Człowiek vs AI!**